공유 오피스 유료 결제 전환율 예측:

머신 러닝을 기반으로 한 비즈니스 제안

결제 전환율 개선을 위해 사용자 행동 로그를 기반으로 결제 가능 고객을 예측하는 모델을 구축하였다. 본 분석은 클래스 불균형 환경에서 정확도보다 결제 고객을 놓치지 않는 것을 우선 목표로 하여 Recall 중심으로 모델을 설계하고 평가하였다. 특히 Confusion Matrix 기반 EDA를 통해 예측 실패 고객(FN)의 특성을 분석함으로써, 모델의 한계와 함께 마케팅 전략에 활용 가능한 인사이트를 도출하고자 한다.

---

1. 분석 개요

- 분석 기간 : 2025.12.23. ~ 2026.01.07.
- 분석가 : 노유림, 세빌, 이재영, 정담연
- 분석 도구 : Python
    - Pandas, NumPy: 데이터 전처리 및 집계
    - Scikit-learn: 분류 모델 학습 및 성능 평가
    - Matplotlib, Seaborn: 모델 성능 및 사용자 그룹 비교 시각화

2. 데이터 개요

2.1 데이터 설명

- 사용자 방문 로그 데이터
- 공유오피스 서비스의 2년 8개월치(2021.05.01 ~ 2023.12.31) 데이터

테이블명	테이블 설명	주요 컬럼
trial_register	3일체험 신청자	user_id, trial_date
trial_access_log	3일체험 신청자 일자별 방문기록	user_id, access_time, stay_time
trial_visit_info	3일체험 신청자 출입 기록	user_id, visit_date, stay_time, site_id
trial_payment	3일체험 신청자 결제 여부	user_id, is_payment
site_area	지점별 면적	site_id, area_pyeong

2.2 데이터 구조 및 주요 변수

본 분석은 사용자 단위의 결제 여부 예측을 목적으로 하므로, 여러 로그 테이블에 분산된 데이터를 **user_id** 기준으로 통합하여 분석을 수행하였다. 분석 과정에서는 방문 로그 및 체류 시간 정보를 사용자 단위로 집계하여 결제 행동을 설명할 수 있는 파생 변수를 생성하였다.

1) 주요 분석 단위

- 사용자 단위**(user_id)**
  - 모델의 예측 대상 단위
  - 결제 여부(is_payment)를 종속 변수로 설정
- 방문 행동 단위
  - 방문 일자, 방문 지점, 체류 시간 등 사용자의 이용 패턴을 설명하는 기초 데이터
  - 단일 방문 기록은 분석 단위가 아닌, 사용자 수준으로 요약하여 활용

2) 주요 변수 구성 방향

- 체류 시간 기반 지표
  - 사용자의 서비스 이용 강도를 설명하기 위해 체류 시간 합계, 평균, 최소·최대값 등의 지표를 활용

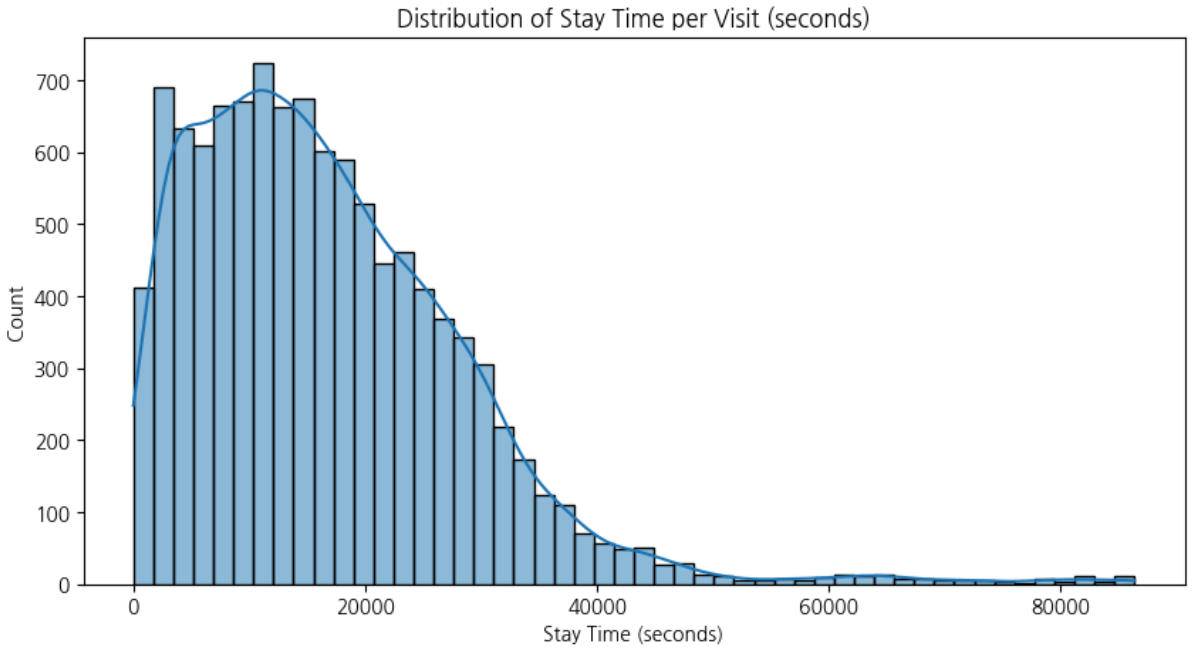

- 방문 시점 기반 변수
  - 최초 방문 시점을 기준으로 연·월 단위 변수(year, month)를 생성하여 시기별 이용 특성을 반영

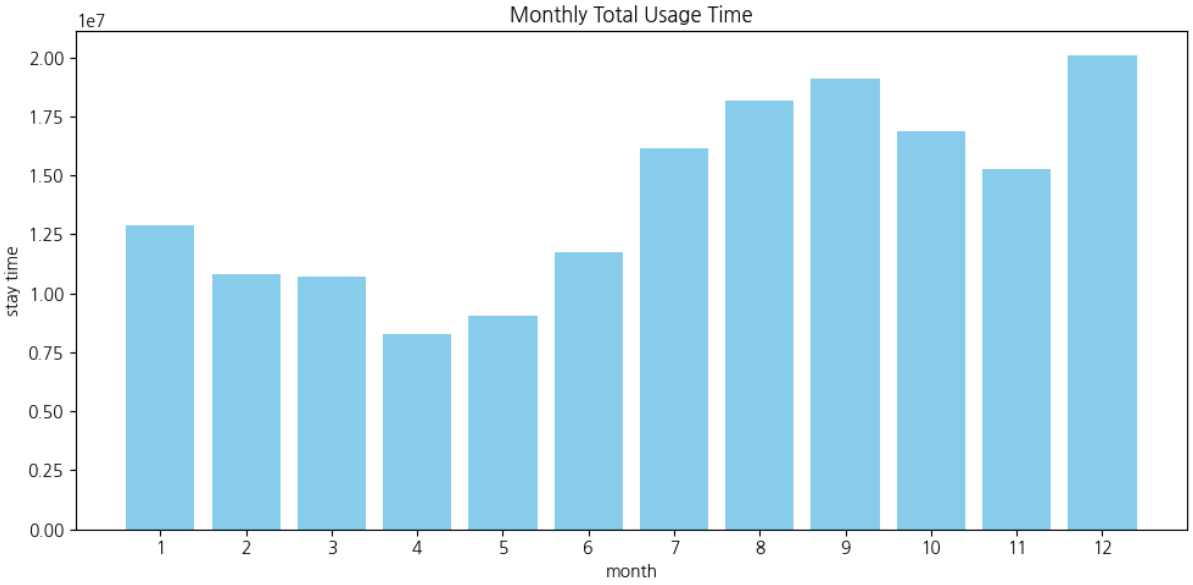

- 지점 정보 변수

- 방문 지점(site_id) 및 지점 면적(area_pyeong)을 활용하여 물리적 환경 요인이 이용 행동에 미치는 영향을 분석에 포함

3) 종속 변수 정의

- 결제 여부**(is_payment)**

  3일 체험 이후 실제 결제가 발생한 경우 1, 결제가 발생하지 않은 경우 0으로 정의

결제 여부(is_payment)	count
0 (비결제)	5995
1 (결제)	3664

---

3. 데이터 전처리

3.1 결측치 및 이상치 처리

- 전체 중복행 제거
- 날짜 타입 변경
- 출입 시간대 계산이 필요할 수 있어서 leave_time 컬럼 삭제 (enter_time 컬럼만 사용)
- trial_access_log 테이블의 내용이 trial_visit_info 테이블과 겹쳐서 더 세부적인 trial_visit_info 테이블만 사용

3.2 머신 러닝 모델을 위한 데이터 병합 및 전처리

- 모델을 위해 고유한 user_id를 기준으로 merge를 사용하여 데이터 병합
- 가입을 했으나 오피스를 이용하지 않았던 유저들의 stay_time 값이 결측치여서 제거
- is_payment (결제 여부) 칼럼을 종속 변수(타겟)로 설정
- 새로 생성한 컬럼들:
  - year: 연
  - month: 월
  - stay_time_mean: 재실시간_평균

    - stay_time_sum: 재실시간_합계
    - stay_time_min: 재실시간_최소값
    - stay_time_max: 재실시간_최값
    - site_id_max: 가장 오래 이용한 사이트

- 모델 검증을 위한 테이블의 최종 상태:
    - trial_date, user_id, visit_days, site_id, are_pyeong, year, month, is_payment

---

4. 문제 정의 및 평가지표

4.1 예측 문제 정의

본 분석의 목적은 사용자 행동 로그를 기반으로 3일 체험 이후 실제 결제로 이어질 가능성이 있는 사용자를 사전에 예측하는 것이다. 이에 따라 본 문제는 사용자를 결제**(1)** **/** 비결제**(0)**로 분류하는 이진 분류 문제로 정의하였다.

4.2 평가지표 선정 이유

본 데이터는 결제 고객 비율이 상대적으로 낮은 클래스 불균형 데이터로 구성되어 있다.
이와 같은 환경에서는 단순 Accuracy 지표만으로는 모델의 실질적인 성능을 적절히 평가하기 어렵다. 이에 본 분석에서는 Precision, Recall, F1-score를 함께 비교하였으며, 그중 **Recall**을 핵심 평가지표로 선정하였다.

- **Precision(**정밀도**)**
  모델이 결제할 것으로 예측한 사용자 중 실제 결제한 사용자의 비율
  → 마케팅 비용 효율과 직결되는 지표
- **Recall(**재현율**)**
  실제 결제한 사용자 중 모델이 결제할 것으로 예측한 사용자의 비율
  → 결제 고객을 얼마나 놓치지 않았는지를 나타내는 지표
- **F1-score**
  Precision과 Recall의 조화 평균으로, 두 지표 간 균형을 종합적으로 평가하는 지표

Recall을 핵심 지표로 선정한 이유

본 분석에서 FN(False Negative)은 실제로 결제한 사용자임에도 모델이 비결제로 예측한 경우를 의미한다. 이는 곧 결제 가능 고객을 마케팅 대상에서 제외하는 상황으로 이어지며, 비즈니스 관점에서 가장 큰 기회 비용을 발생시킨다.

---

5. 모델링

5.1 모델 후보

- Decision Tree
- Random Forest
- XGBoost

5.2 학습 및 검증 전략

모델 성능을 공정하게 비교하기 위해 동일한 학습 및 검증 조건을 적용

- 데이터 분할 방식 : Train/Test Split: 80% / 20%
- 클래스 비율 유지 : stratify=y 적용 → 결제/미결제 비율 유지

5.3. 모델 후보 비교 결과

- **Decision Tree**는 해석은 용이하나 Recall 측면에서 한계를 보였으며,
- **XGBoost**는 일부 성능 향상을 보였으나 모델 복잡도가 상대적으로 높았다.
- **Random Forest**는 전반적으로 가장 안정적이며 높은 Recall을 기록하였다.

결제 고객을 놓치지 않는다는 목적에 가장 부합하는 모델로 **Random Forest**를 최종 모델로 선정하였다.

5.4. Random Forest 구조 파라미터 튜닝 결과

각 파라미터를 하나씩 고정/변경하며 Recall 변화를 관찰

```
RandomForestClassifier(
        n_estimators=100,
        max_depth=3,
        min_samples_split=20,
        min_samples_leaf=15,
        max_features="sqrt",
        class_weight="balanced",
        random_state=42,
        n_jobs=-1
)
```

- 과적합 억제
- Recall 중심 설계
- Threshold 조정에 최적화된 구조
- Confusion Matrix 시각화

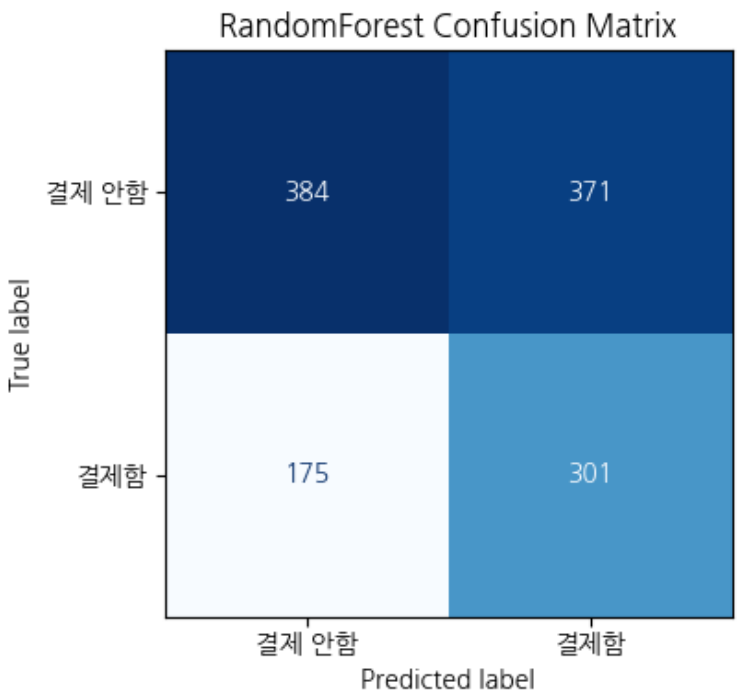

5.5. Threshold 조정 결과

기본 threshold(0.5) 대신 다양한 threshold 실험

Threshold	Recall	Precision	Positive Rate
0.30	1.00	0.39	1.00
0.35	0.996	0.39	0.99
0.40	**0.92**	**0.40**	**0.89**
0.45	0.77	0.42	0.71
0.50	0.63	0.45	0.55

- 최종 선택 Threshold = 0.4

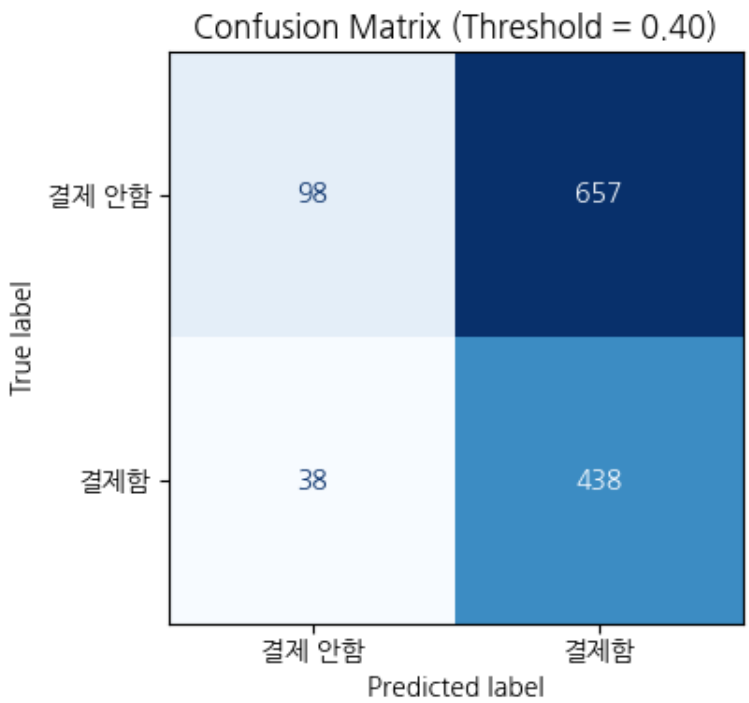

6. Confusion Matrix 기반 모델 EDA

6.1 사용자 유형(TP / FP / FN / TN) 정리

그룹	행동 특성	해석
TP	체류 시간은 길지 않지만 결제 시그널이 명확	즉시 결제형 고객
FP	체류 시간은 짧으나 결제 시그널이 유사	잠재 결제형 고객
TN	체류 시간이 매우 김	탐색·구경형 사용자
FN	체류 시간이 매우 김 + 실제 결제	고관여·신중형 결제 고객

6.2 모델 EDA 핵심 결론

6.2-1. 모델이 학습한 방향성

- 모델은 체류 시간이 길어질수록 결제하지 않을 가능성이 높다고 학습
- 즉, “오래 머문다 = 결제”라는 직관과 반대되는 방향으로 분류가 이루어짐

그래프와 평균 비교 결과, TN, FN 그룹에서 체류 시간이 가장 길게 나타났고 TP, FP 그룹은 상대적으로 체류 시간이 짧게 나왔다. 다시 말해 모델은 체류 시간이 긴 사용자를 Negative(비결제)로 분류하는 경향을 보여준다.

6.2-2. 왜 이런 결과가 나왔는가?

모델 구조

- RandomForest + shallow depth(max_depth=3)
- Recall 중심 설계
- Threshold = 0.4

다수의 결제 고객이 짧은 체류 후 빠르게 결제한 패턴을 강하게 학습 했고 반대로, 체류 시간이 매우 긴 고객은 “탐색형 사용자”로 일반화되어 Negative 쪽으로 밀렸다.
그 결과, 장기 탐색 후 결제한 고객(FN)을 일부 놓치게 되었다.

6.3. FN 고객 분석

6.3-1. FN의 실제 정체

- FN 고객은 결제 고객임에도 체류 시간이 TP보다 현저히 길었음
- 이는 FN이 충동적·즉시 결제형이 아닌 충분한 탐색과 고민 후 결제한 고관여 고객임을 암시한다.
- 즉, 모델이 “틀리게 분류한 고객”이라기보다 “모델의 설계 철학 밖에 있던 고객 유형”

6.3-2. 왜 FN을 놓쳐도 모델이 실패라고 보기 어려운가

- 모델 목적: 즉시 전환 가능 고객을 놓치지 않는 것
- FN은 단기 마케팅 타겟이 아니라 장기 설득·정보 제공이 필요한 고객
- 따라서 FN 발생은 모델 오류라기보다 타겟팅 전략의 분리 필요성을 보여주는 신호

---

7. Feature 관점 분석

7.1 주요 Feature 중요도

- 체류 시간 관련 변수(stay_min, stay_max, stay_mean, stay_sum) 영향이 크다
- site_id 관련 변수 영향이 제일 낮다

7.2 결제 / 미결제 그룹 비교 결과

- 미결제 그룹의 체류 시간 관련 변수들의 평균/중앙값이 결제 그룹보다 전반적으로 높게 나타났다

	미결제 그룹	결제 그룹
stay_mean(평균 체류 시간)	15814.86	13731.63

- 매장 면적 (area_pyeong)의 평균/중앙값이 두 그룹 (결제/미결제) 모두 유사했다
  - 약 110평
- 추가: 결제 그룹이 미결제 그룹보다 평균 방문 일수(visit_days)가 약간 높게 나타났다
  - 결제 그룹 평균: 1.86일, 미결제 그룹 평균: 1.63일

8. 모델 한계 및 개선 방향

8.1 분석 한계

- 행동 로그 기반 예측의 한계:
  - 사용자 체류시간·방문일수 등 가시적인 행동 신호만 활용하였기 때문에, 실제 결제 의사결정에 영향을 미칠 수 있는 내적 동기(오피스 사용 목적, 선호도 등) 등 비정형 요인을 반영하지 못 했다.
- 클래스 불균형 및 **FN** 중심 문제:
  - 결제 고객 비율이 낮은 불균형 구조로 인해 Recall 중심 설계를 적용하였으나, FN(실제 결제 고객 오분류)의 특성을 완전히 설명하기에는 현재 Feature 구성이 제한적이였다.
- 변수 간 상관 구조의 단순성:
  - 체류시간 관련 Feature들이 모델 내 가중치를 과도하게 점유하면서, 특정 변수 의존도가 높아지고 site_id, area_pyeong 등 물리적 환경 요소의 영향이 낮게 산출되는 현상이 발생했다.

8.2 향후 개선 방향

- 마케팅 노출 데이터 결합
  - 쿠폰 수신 여부, 광고 접점 등 외부 요인 추가
- 행동 기반 Feature 확장
- FN 고객 중심 Feature 재설계
  - stay_time 단순 길이 외, 방문 패턴・시간대 등의 구조적 요인 반영

9. 결론

수치 개선 비교	파라미터 튜닝 이후	Threshold 조정 이후
Recall	0.63	**0.92**
FN	175	**38**

본 프로젝트는 결제 가능성이 있는 고객을 최대한 놓치지 않는 것을 최우선 목표로 설정하고, Random Forest 모델에 **Recall** 중심의 평가 전략을 적용하여 공유 오피스 체험 고객의 결제 전환 가능성을 예측하는 기초 모델 구조를 구축하였다.

9.1. Recall 중심 모델링 전략의 유효성

본 분석에서는 **FN(False Negative)—**즉 실제 결제 고객을 예측에서 제외하는 경우**—**를 최소화하는 것을 핵심 과제로 설정하였다.

Confusion Matrix 기반 모델 EDA 결과, 체류 시간이 길수록 결제로 이어질 것이라는 초기 가설과 달리, 체류 시간이 길어질수록 오히려 비결제로 분류되는 경향이 확인되었다. 즉, 장시간 탐색하는 사용자보다는 짧은 시간 내 결제 시그널을 보이는 사용자가 실제 결제로 이어지는 경우가 많았다.

이에 따라 본 모델은 체류 시간이 비교적 짧더라도 결제 가능성이 있는 사용자를 적극적으로 포착하도록 설계되었으며, threshold 조정을 통해 실제 결제 고객을 효과적으로 식별할 수 있었다. 일부 FP 증가가 발생하였으나, 이는 마케팅 비용 관점에서 수용 가능한 수준으로 판단된다.

9.2. 데이터 기반 마케팅 타겟팅 활용 시사점

모델 EDA 결과는 체류 시간이 길어질수록 결제 확률이 낮아질 수 있다는 역설적 패턴을 보여주었다. 이에 따라 본 분석에서는 체류 시간이 짧은 초기 체험 구간에서 결제를 유도하는 전략이 중요함을 시사한다.

구체적으로, 본 모델은 다음과 같은 마케팅 전략 수립에 활용될 수 있다.

- 체험 초기 단계에서 결제 가능성이 높은 고객을 사전에 선별하여 즉시 결제 유도 메시지, 한정 할인, 시간 제한 프로모션을 집중적으로 노출
- 체류 시간이 길어지기 전에 결제 시점에 대한 명확한 가이드와 혜택을 제공함으로써 탐색형 사용자로 전환되기 전 결정을 유도
- 장시간 체류하는 사용자(FN 유형)에 대해서는 즉각적인 할인보다 정보 제공, 비교 콘텐츠, 후기 중심의 장기 설득형 마케팅 전략으로 분리 대응

이를 통해 단순히 “많이 이용하게 만드는 것”이 아니라, “적절한 시점에 결제를 유도하는 전략적 개입”이 전환율 개선에 더 효과적일 수 있음을 확인하였다.